UV지수 주기성과 급감 분석을 통한 모델 개발

참 가 번 호	220224	팀 명 ※ 반드시 참가신청 시 작성한 팀명	반가운단비

1. 문제 소개

현안 문제는 기상 위성 정보를 사용하여 여름철 자외선 산출 기술을 개발, 개선하는 것이다.
제공 데이터는 2020년 1월부터 2021년 12월까지의 관측 자료이며 시간 정보, 위치 정보, 밴드 값 등 27개의 변수(feature)로 구성되어있다.

2. 개요

본 제출작은 8/3일 오후 4시 55분 기준 RMSE: 0.580522, 1등이다. 해당 과제를 해결하기 위해 수행한 전체 과정은 다음과 같다. 탐색적 데이터 분석 과정에서는 데이터를 분석하고 결측치가 있는 원본데이터를 전처리 할 방법을 모색하였다. 이어서 모델에 사용 할 데이터 셋을 생성 후 트리 기반 구조의 앙상블 모델 등을 사용한 예측 모델 개발 및 그 결과에 대해 비교한다.

<그림 2-1. 보고서 개요>

3. 데이터 분석 및 데이터 전처리

3-1. 데이터 분석

1) 시간에 따른 UV지수는 주기성을 갖는다. 일몰시간 이후부터 일출시간 이전까지 UV지수는 0에 가까운 값이다. 아래 <그림 3-1> 왼쪽은 131번 관측소의 시간에 대한 UV지수를 나타낸 것이다. <그림 3-1> 오른쪽은 관측소 131번에 2020년 1월 ~ 2021년 12월 사이 시간에 따른 UV지수 그래프이다. 계절주기성 또한 갖는 것을 확인 할 수 있다. 다른 관측소에서 관측된 UV지수도 아래와 같은 주기성을 갖는다.

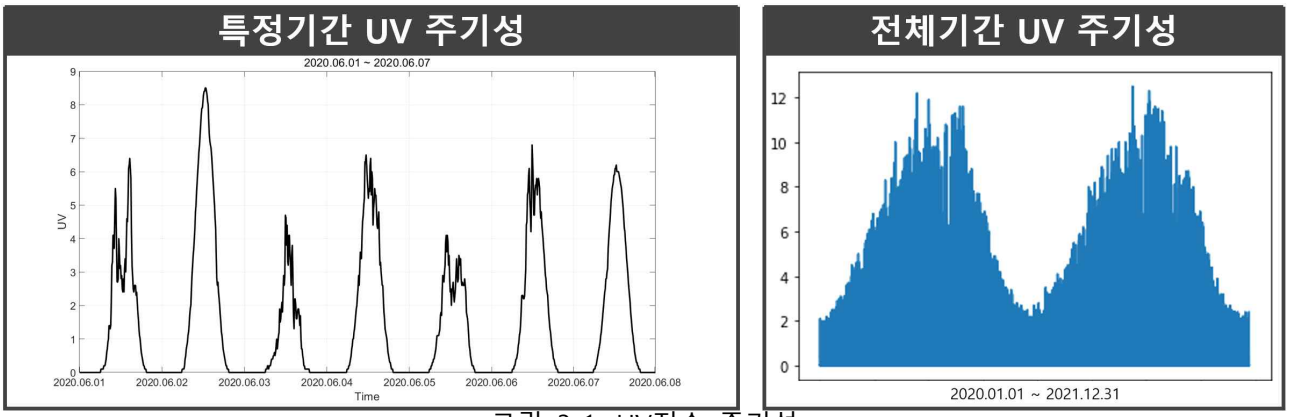

<그림 3-1. UV지수 주기성>

2) 시간에 따른 ESR(대기외 일사량)도 주기성을 갖는다. <그림 3-2> 왼쪽, 오른쪽 그래프는 서로 가까운 날 세 개의 관측소에서의 시간에 따른 ESR 그래프이다. 관측소와 상관없이 왼쪽, 오른쪽 그래프 모두 시간에 따른 ESR 그래프 형태가 비슷한 걸 확인할 수 있다.

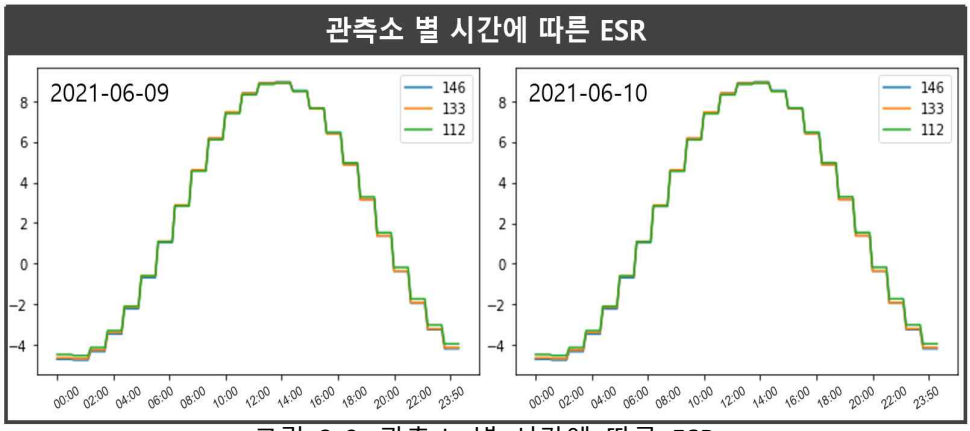

<그림 3-2. 관측소 별 시간에 따른 ESR>

3) <그림 3-3> 왼쪽 그래프를 보면 2021년 6월 9일은 UV지수 그래프가 <그림 3-2> 2021년 6월 9일 ESR 그래프와 유사함을 알 수 있다. 하지만 그 다음날인 2021년 6월 10일은 UV지수 그래프가 급감하는 구간이 생겨 위 ESR 그래프의 형태와 덜 유사하다는 것을 알 수 있다.

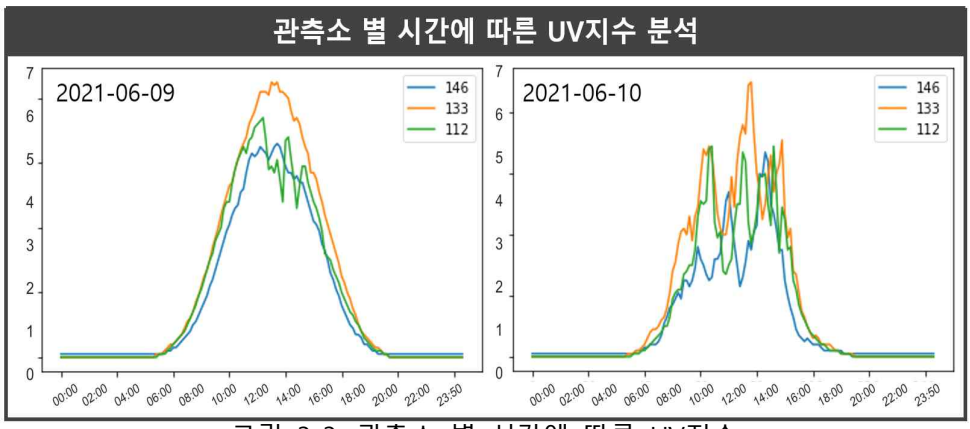

<그림 3-3. 관측소 별 시간에 따른 UV지수>

4) 대기외 일사량이 높다면 관측소에서 측정한 UV지수도 높아야 한다. 하지만 위 3-1-2, 3-1-3 분석과 <그림 3-4-b>를 통해 그렇지 않은 경우가 많다는 것을 확인 하였다. 이는 태양광이 지면에 닿기 전 대기내 어떤 원인으로 인해 에너지가 손실되기 때문이라 판단하였다. 아래 <그림 3-4-a>를 통해 112, 133, 146 관측소가 서로 가까이 위치하여 동일한 기상현상의 영향권안에 들 수 있음을 확인 할 수 있다. 이는 원본 데이터외 UV지수 급감을 학습할 수 있는 기상현상에 대한 외부데이터가 필요하다는 판단에 근거가 되었다.

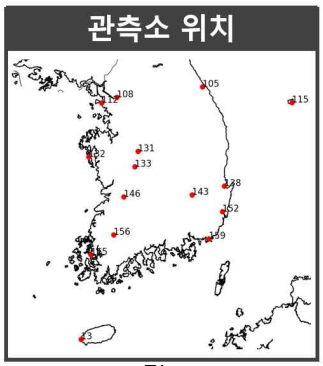

<그림 3-4-a>

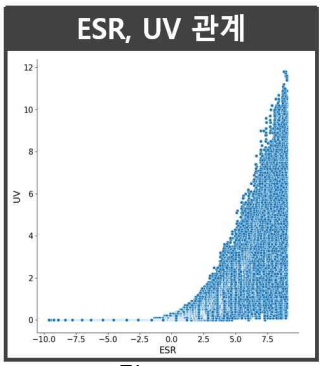

<그림 3-4-b>

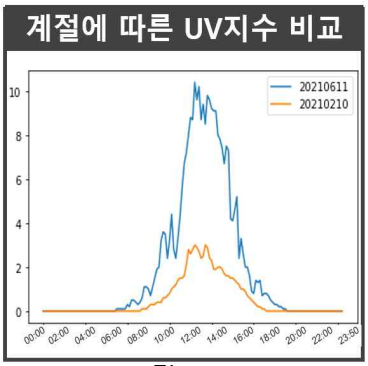

<그림 3-4-c>

5) <그림 3-4-c>는 131번 관측소에 대한 서로 다른 계절에 측정된 UV지수 그래프이다. 두 그래프를 유계구간내 정의 된 함수로 볼 때 적분을 취해 넓이를 구할 수 있고 두 넓이 차이가 큼을 확인 할 수 있다. 특정시점에 온도가 높다는 변수는 UV지수 함수 넓이에 큰 영향을 주지 못한다. 이유는 여름철 해가진 새벽 2시에 기온이 가을철 해가 쨍쨍 내리쬐는 오후 3시 기온보다 높을 수 있기 때문이다. 따라서 밤낮과 계절에 주기성을 보이는 UV지수에 맞춰 각각 하룻동안 최고기온과 월별 합계 일사량을 변수로 추가하였다.

6) 원본 데이터내 결측치(-999)가 있음을 확인하였다. 아래 <그림 3-5>는 각 변수(Feature)별 결측치 비율을 그래프화 한 것이다. 본 데이터 탐색으로 데이터 전처리로 새로운 변수 추가와 결측치 제거를 계획하게 되었다.

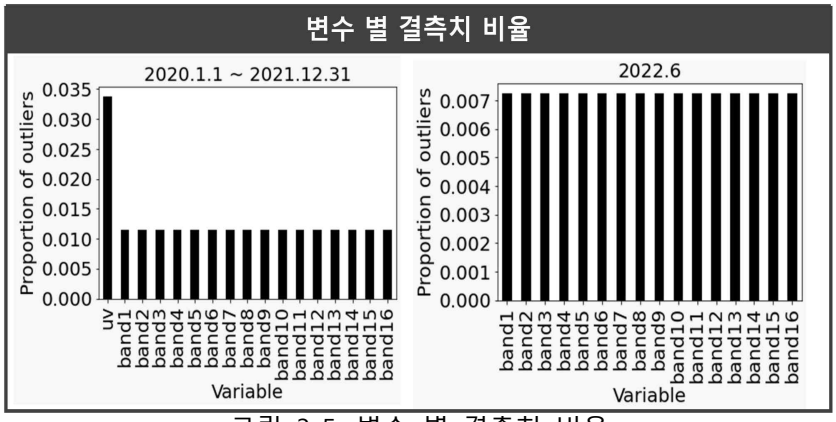

<그림 3-5. 변수 별 결측치 비율>

3-2. 데이터 전처리

1) 결측치 제거

- [Training data (2020년 1월~ 2021년 12월)]
  1. 데이터 분석 3-1-1을 통해 일몰부터 일출전까지 UV지수가 0에 가까운 숫자 임을 알 수 있다. 아래 <표 3-6>은 왼쪽은 원본 데이터중 0시부터 5시 50분까지 각 UV지수 별 비율이다. 오른쪽은 20시부터 23시 50분까지 각 UV지수 별 비율이다. 따라서 오후 20시부터 오전 5시 50분까지 UV지수 결측치는 모두 0으로 채웠다.

특정 시간대 UV지수 별 비율

UV	비율	UV	비율
0	93%	0	94%
-999	3%	-999	3%
0.1	2%	0.1	2%
0.2	< 0.1%	0.2	< 0.1%

<표 3-6. 일몰부터 일출전까지 UV지수 별 비율>

  2. 오전 6시부터 오후 7시 50분 사이 UV지수 결측치가 포함된 데이터는 모두 제거 하였다.
  3. 이후 Band1 ~ Band16 변수에 결측치가 포함된 데이터는 극소수라 모두 제거 하였다.
- [Test data (2022년 6월)]
  1. 결측치가 존재하는 Band1 ~ Band16 변수에 선형 보간법으로 결측치를 채웠다.

2) 외부데이터 추가 및 변수 생성

1. UV지수 급감 구간을 반영할 외부데이터로 강수량, 전운량, 중하층운량 모두 고려 하였으나 결측치가 많은 강수량 데이터는 제외하고 전운량과, 중하층운량만 외부데이터로 사용하였다. (출처: 모든 외부데이터 출처는 기상포탈, 외부데이터 문서에 상세기록함)

2. 전운량과, 중하층운량은 시간자료이고 주어진 UV데이터는 분 자료이다. 따라서 전운량, 중하층운량 데이터를 선형 보간법으로 결측치를 채웠다.
3. 주기성을 확인한 데이터 분석 3-1-1을 토대로 월과 시간,분 변수를 데이터로 추가하였다.
4. 데이터 분석 3-1-5를 토대로 UV지수 면적을 반영할 수 있는 변수로 특정 시간대가 아닌 일, 월 단위로 월별 합계 일사과 하루 최고 온도를 추가하였다. 결측치는 같은 날, 같은 월이면 모두 같은 값으로 채웠다.

3) 데이터 그룹화

원본 데이터는 총 15개 관측소에 대한 관측 자료들이 존재한다. 하지만 13, 132, 152 관측소는 추가한 외부데이터중 일부 변수가 존재 하지 않는다. 따라서 외부데이터 변수가 모두 포함되어있는 12개 관측소는 외부데이터 모든 변수를 사용할 수 있으므로 이를 그룹1이라 하고 12개 관측소 UV지수 예측에 사용하였다. 그리고 외부데이터 중 일부변수가 없는 3개 관측소에 대해선 외부 데이터를 포함해도 결측치로 모델 학습에 부정적인 영향을 미칠 수 있기에 외부 데이터를 모두 제외한 15개 관측소 데이터를 그룹2라 하고 이를 13, 132, 152 관측소 UV지수 예측에 사용하였다.

4. 모델 개발

4-1. 모델 개발 과정

1) 고전적 통계 분석 방법론인 회귀분석을 첫 번째로 사용하였다. 추정된 계수를 바탕으로 2020년 6월 1일에 13번 관측소에서 관측된 UV지수와 모델의 예측 결과를 비교한 그림은 아래와 같다. 예측 값과 실제 값에 오차가 커 예측모델로 사용은 어려웠다.

회귀분석 결과

```
Coefficients:
              Estimate Std. Error  t value Pr(>|t|)
(Intercept)  1.673e+01  1.572e-01  106.433  < 2e-16 ***
lon          3.688e-03  7.587e-04    4.861 1.17e-06 ***
lat          2.971e+00  7.530e-02   39.454  < 2e-16 ***
band1        4.910e+01  1.788e-01  274.584  < 2e-16 ***
band2       -5.749e+01  2.083e-01 -275.984  < 2e-16 ***
band3       -6.281e+00  4.643e-02 -135.274  < 2e-16 ***
band4        1.166e+01  4.917e-02  237.098  < 2e-16 ***
band5        4.014e+00  4.485e-02   89.503  < 2e-16 ***
band6        9.811e+00  3.465e-02  283.189  < 2e-16 ***
band7       -5.999e-02  2.744e-04 -218.636  < 2e-16 ***
band8       -3.034e-02  1.138e-03  -26.660  < 2e-16 ***
band9        5.301e-02  1.968e-03   26.932  < 2e-16 ***
band10      -1.373e-02  1.455e-03   -9.434  < 2e-16 ***
band11       1.800e-01  1.837e-03   98.002  < 2e-16 ***
band12       1.878e-02  4.782e-04   39.265  < 2e-16 ***
band13      -1.716e-01  2.647e-03  -64.820  < 2e-16 ***
band14       4.790e-01  3.365e-03  142.378  < 2e-16 ***
band15      -3.356e-01  2.102e-03 -159.682  < 2e-16 ***
band16      -1.492e-01  1.109e-03 -134.569  < 2e-16 ***
solarza     -6.079e-02  1.566e-04 -388.305  < 2e-16 ***
sateza      -2.661e+00  6.649e-02  -40.017  < 2e-16 ***
esr         -2.937e-01  1.095e-03 -268.292  < 2e-16 ***
height       1.769e-03  4.227e-05   41.838  < 2e-16 ***
landtype    -4.456e-02  1.052e-03  -42.353  < 2e-16 ***
```

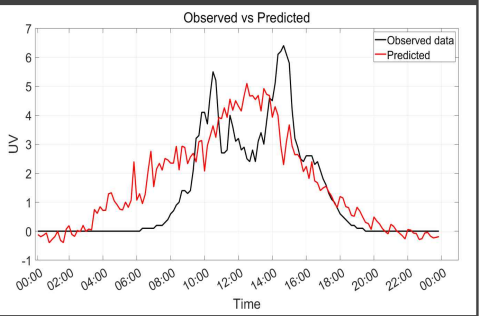

<그림 4-1. 회귀분석 결과>

2) 다양한 데이터 그룹화 시도

1. 아래 <그림 4-2>를 보면 모든 관측소에서 일몰시간 이후 일출시간 이전까지 UV지수는 0에 가깝다. 그리고 그 외 시간대 UV지수는 0보다 큰 값을 갖는 것을 확인 할 수 있다. 이에 우리는 전자를 기간1, 후자를 기간2로 나눠 데이터를 그룹화 하였다.

활동기간과 비활동기간으로 그룹화

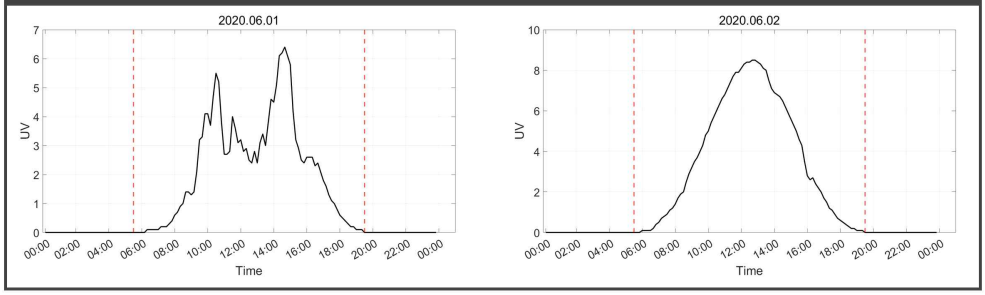

<그림 4-2. 다양한 데이터 그룹화 시도 1>

2. <그림 4-3> 왼쪽 그림은 위도와 자외선이 밀접하게 관련 있음을 보인다. 이에 <그림 4-3> 오른쪽 그림과 같이 데이터를 3개로 나눠 그룹화 하였다. (출처: koreareview.co.nz/uv_protection)

3. 데이터전처리 3-2-3과 같은 과정이다 <그림 4-4>참고.

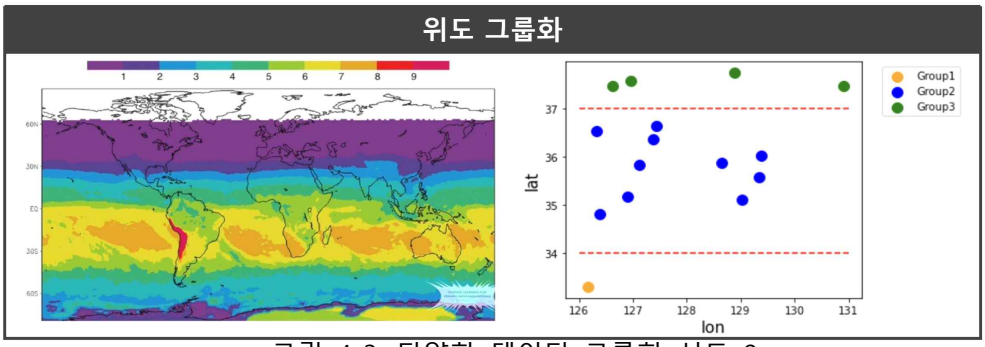

<그림 4-3. 다양한 데이터 그룹화 시도 2>

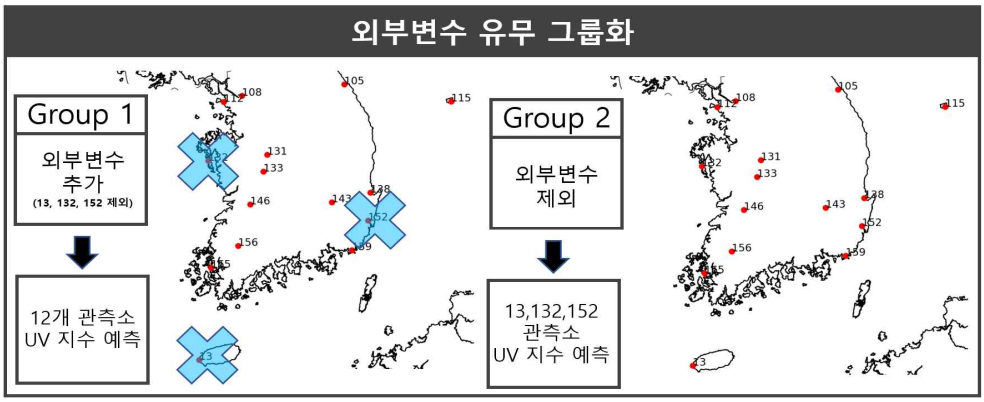

<그림 4-4. 다양한 데이터 그룹화 시도 3>

4-2. 최종 모델 선택

각 데이터 그룹화를 비교 분석하기 위한 모델로 트리 기반 모델인 LGBM, XGB 그리고 딥러닝 모델인 Tabnet을 고려하였다. 각 그룹화 방법에 대해 위 3개 모델로 성능을 비교 하였고 그 결과 계산속도와 RMSE를 고려해 데이터 그룹화는 구름변수 유무 그룹화, 모델은 LGBM을 선택하였다.

각 그룹화 방법 별 모델 비교

그룹화 방법	XGB	Tabnet	LGBM
그룹화 하지 않음	0.735	0.651	0.637
그룹화 1(기간)	0.732	0.672	0.633
그룹화 2(위도)	0.732	0.668	0.637
그룹화 3(변수)	0.718	0.646	0.620

<표 4-5. 각 그룹화 방법 별 모델 비교>

5. 결론

5-1. 모델학습 후 Shap value 산출

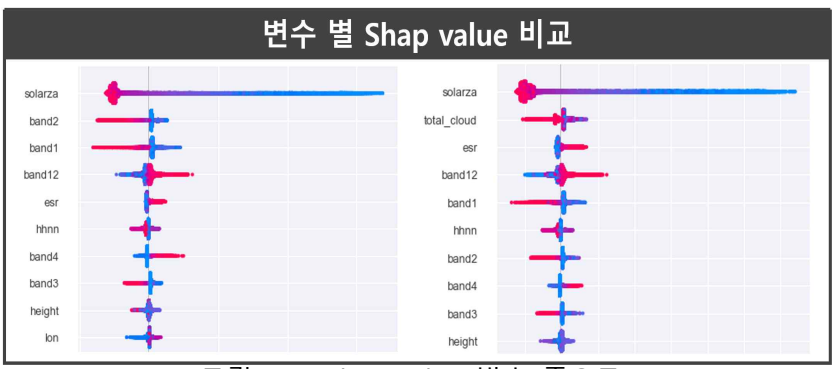

<그림 5-1. Shap value 변수 중요도 >

모델 학습 후 Shap value를 산출하여 데이터 변수중 모델 학습에 영향을 끼친 변수를 시각화 하였다. <그림 5-1>을보면 구름 변수(total_cloud)와 추가하지 않은 왼쪽 모델과 다르게 오른쪽 모델은 구름 변수가 모델학습에 큰 영향을 주었음을 확인 할 수 있다. 마찬가지로 추가한 월 변수도 모델성능 향상에 기여하였음을 확인하였다. 그 외 추가한 외부변수들에 대하여서는 Shap value를 확인하지 못하였으나 추가하기전 보다 검증 RMSE와 모델내 성능 모두 향상됨을 확인 하였다.

5-2. 제출작 전체 프로세스

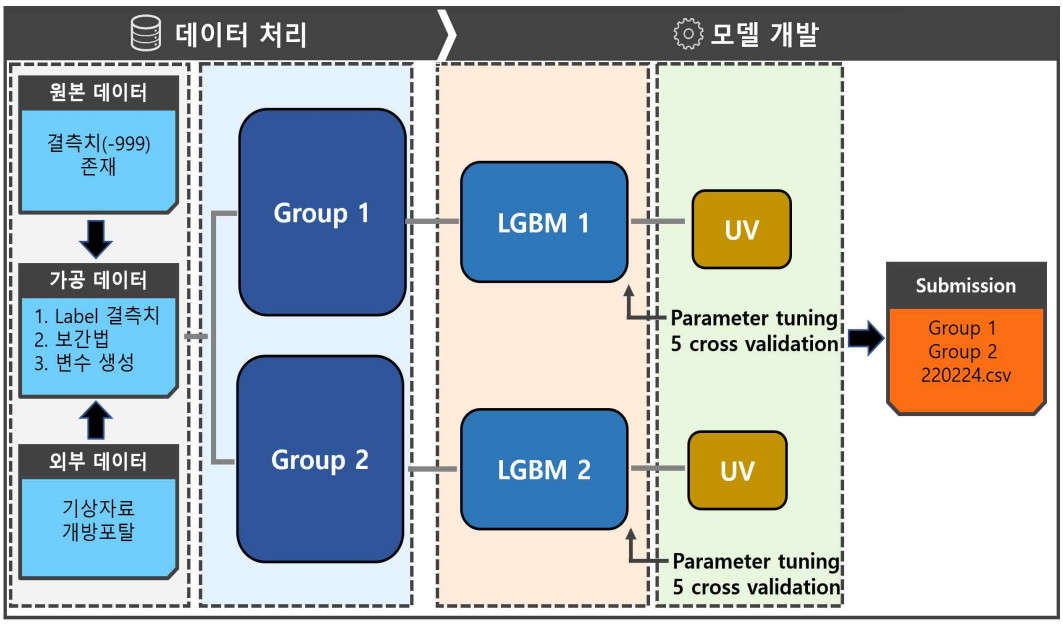

<그림 5-2. 제출작 전체 프로세스 도식도>

1)데이터 전처리

- 본 보고서 3-2에 서술한 과정과 동일하다.

2)모델

- 각 그룹은 데이터가 다르므로 서로 다른 LGBM을 사용한다.
- Validation data:2021년 5~7월 /Train data: Validation data 외 기간 /Test data: 2022년 6월
- 5-fold cross validation, 파라미터 서치로 Optuna를 사용하여 파라미터 튜닝 진행 하였고 튜닝을 통해 모델내 검증과 사이트 제출 검증 모두 성능 향상이 있었다.

3)하이퍼 파라미터 값

- LGBM1: num leaves = 511, learning rate = 0.009950190949282378, colsample bytree = 0.9, max depth = 13, n estimators = 1670, early stopping = 25, min child samples = 82, subsample: 0.4736944981194948
- LGBM2: num leaves = 511, learning rate = 0.009994761730516164, colsample bytree = 0.9, max depth = 14, n estimators = 1997, early stopping = 25, min child samples = 73, subsample: 0.6224

본 제출작은 탐색적 데이터 분석을 통해 UV지수에 주기성과 기상현상에 의한 UV지수 급락을 분석하고 그에 따라 외부데이터를 수집해 데이터를 그룹화하여 학습하였다. 이로서 결측치를 배제하여 좋은 성능의 모델을 개발하였다. 또한 개발한 모델에 변수를 Shap value로 분석해 탐색적 데이터 분석을 통해 수집한 외부데이터에 타당성을 보였다. 본 모델을 통해 UV지수를 관측하지 않는 관측소에서도 높은 정확도에 UV지수를 얻을 수 있다.

Reference

[1]tabnet
Arik, S. Ö., Pfister, T. (2021, May). Tabnet: Attentive interpretable tabular learning. In Proceedings of the AAAI Conference on Artificial Intelligence (Vol. 35, No. 8, pp. 6679-6687).
[2]shap value
Mokhtari, K. E., Higdon, B. P., Başar, A. (2019, November). Interpreting financial time series with SHAP values. In Proceedings of the 29th Annual International Conference on Computer Science and Software Engineering (pp. 166-172).
[3] xgb
Chen, T., He, T., Benesty, M., Khotilovich, V., Tang, Y., Cho, H., Chen, K. (2015). Xgboost: extreme gradient boosting. R package version 0.4-2, 1(4), 1-4.
[4] lgbm
Abou Omar, K. B. (2018). XGBoost and LGBM for Porto Seguro's Kaggle challenge: A comparison. Preprint Semester Project.
[5] optuna
https://optuna.org/